

## Descens de gradient

El gradient d'una funció escalar de diverses variables és un vector que conté totes les seves derivades parcials, i indica la direcció de màxim creixement de la funció en cada punt del seu domini.

El descens de gradient és un algoritme d'optimització iteratiu utilitzat per trobar el mínim (local o global) d'una funció. Sigui  $J(\theta)$  una funció de cost (o pèrdua) diferenciable, on  $\theta \in \mathbb{R}^n$  representa el vector de paràmetres del model que volem optimitzar. L'objectiu és trobar el valor de la variable  $\theta$  que fa que la funció assoleixi el seu valor mínim:

$$\theta^* = \arg \min_{\theta} J(\theta).$$

El descens de gradient assoleix aquest objectiu actualitzant iterativament els paràmetres en la direcció oposada al gradient de la funció de cost, ja que el gradient  $\nabla_{\theta} J(\theta)$  indica la direcció de màxim creixement de la funció. Movent-nos en la direcció oposada, ens acostem a un mínim.

La regla d'actualització dels paràmetres a cada iteració  $t$  és:

$$\theta_{t+1} = \theta_t - \alpha \nabla_{\theta} J(\theta_t),$$

on:

- $\theta_t \in \mathbb{R}^n$  són els paràmetres del model en la iteració  $t$ .
- $\alpha > 0$  és la **taxa d'aprenentatge** (*learning rate*), un hiperparàmetre que controla la mida del pas a cada actualització.
- $\nabla_{\theta} J(\theta_t)$  és el gradient de la funció de cost respecte als paràmetres, avaluat en  $\theta_t$ .

De manera més explícita, per a cada component  $\theta_i$  del vector de paràmetres:

$$\theta_i \leftarrow \theta_i - \alpha \frac{\partial J(\theta)}{\partial \theta_i}.$$

L'algoritme s'atura quan es compleix algun criteri de convergència, per exemple:

$$\|\nabla_{\theta} J(\theta_t)\| < \epsilon,$$

on  $\epsilon$  és un llindar (*threshold*) petit predefinit, o bé quan s'assoleix un nombre màxim d'iteracions.

## Un exemple pràctic

Donada la funció de dues variables  $f(x, y) = x^2 + 2y^2 + xy - 3x$  que és contínua i diferenciable a tot  $\mathbb{R}^2$ . Aplicarem l'algorisme del descens del gradient de manera analítica seguint la regla d'actualització  $\theta_{t+1} = \theta_t - \alpha \nabla_{\theta} J(\theta_t)$ , on  $J$  és la funció  $f$  i  $\theta$  són  $x, y$ , els paràmetres de la funció.

Per aplicar el descens de gradient necessitem el gradient  $\nabla f(x, y)$ , és a dir, les dues derivades parcials. Per calcular la derivada parcial respecte a  $x$ , tractem  $y$  com una constant:

$$\frac{\partial f}{\partial x} = \frac{\partial}{\partial x} (x^2 + 2y^2 + xy - 3x) = 2x + y - 3.$$

Farem el mateix per calcular la derivada parcial respecte a  $y$ , tractem  $x$  com una constant:

$$\frac{\partial f}{\partial y} = \frac{\partial}{\partial y} (x^2 + 2y^2 + xy - 3x) = 4y + x.$$

El gradient de la funció és:

$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 2x + y - 3 \\ 4y + x \end{bmatrix}$$

A cada iteració  $t$ , els paràmetres  $(x, y)$  s'actualitzen movent-se en la direcció oposada al gradient, escalada per la taxa d'aprenentatge  $\alpha$ :

$$\begin{bmatrix} x_{t+1} \\ y_{t+1} \end{bmatrix} = \begin{bmatrix} x_t \\ y_t \end{bmatrix} - \alpha \begin{bmatrix} 2x_t + y_t - 3 \\ 4y_t + x_t \end{bmatrix}$$

O de manera separada, component a component:

$$x_{t+1} = x_t - \alpha (2x_t + y_t - 3).$$

$$y_{t+1} = y_t - \alpha (4y_t + x_t).$$

Un cop tenim les derivades parcials podem construir l'algorisme en llenguatge Python per automatitzar el procés:

```
def f(x, y):  
    return x**2 + 2*y**2 + x*y - 3*x  
  
def grad_f(x, y):  
    df_dx = 2*x + y - 3
```

```

df_dy = 4*y + x
return df_dx, df_dy

# Hiperparàmetres
x, y = punt_inicial_x, punt_inicial_y # p. ex. (-3.5, 3.0)
eta = taxa_aprenentatge                # p. ex. 0.15
n_iteracions = nombre_de_passes        # p. ex. 50
epsilon = llindar_convergencia         # p. ex. 1e-6

for t in range(n_iteracions):
    df_dx, df_dy = grad_f(x, y)

    # Criteri d'aturada: norma del gradient prou petita
    norma_gradient = (df_dx**2 + df_dy**2) ** 0.5
    if norma_gradient < epsilon:
        break

    # Actualització dels paràmetres
    x = x - eta * df_dx
    y = y - eta * df_dy

    # (opcional) registrar el cost per fer-ne seguiment
    cost_actual = f(x, y)

# En acabar el bucle, (x, y) és l'aproximació al mínim de f

```

El resultat d'aplicar l'algorisme durant 50 iteracions és el següent:




Figure 1: Visualització de l'algorisme del descens del gradient

Codi Python disponible en el següent enllaç.

### Solució analítica

Com que  $f$  és convexa només té un mínim, aquest es troba igualant el gradient a zero. Podem trobar la solució analítica i comprovar que és la mateixa que la que troba l'algorisme:

$$\begin{cases} 2x + y - 3 = 0 \\ 4y + x = 0 \end{cases}$$

De la segona equació:  $x = -4y$ . Substituint a la primera:

$$2(-4y) + y - 3 = 0 \Rightarrow -8y + y - 3 = 0 \Rightarrow -7y = 3 \Rightarrow y = -\frac{3}{7},$$

$$x = -4y = \frac{12}{7}.$$

Per tant, el mínim global s'assoleix a:

$$(x^*, y^*) = \left(\frac{12}{7}, -\frac{3}{7}\right) \approx (1.714, -0.429).$$

Aquest resultat coincideix amb el punt final que obtenia el descens de gradient a la simulació anterior.

### Un exemple més complex

La funció de l'exemple anterior és simple (té dos paràmetres) i només té un mínim. Per tant, el podem trobar de forma analítica, en canvi, la funció  $f(x, y) = \sin(x) * \cos(y) + 0.1 * (x^2 + y^2)$  no té una solució analítica tancada. En aquest cas, aplicant l'algorisme del descens del gradient podem intentar trobar-ho.

En el següent gràfic podem veure com evoluciona l'algorisme depenent del punt d'inici:

Codi Python disponible.




Figure 2: descens de gradient a una funció amb diversos mínims